

Regard de biais sur l'analyse de données : contributions de la statistique au déroulement de la recherche en santé

Félix Camirand Lemyre

Professeur agrégé

Département de mathématiques
UdS

Chercheur régulier

Centre de recherche sur le Vieillissement

Chercheur boursier

FRQS Junior 2

Statisticien méthodologiste & biostatisticien

Co-directeur scientifique

Groupe de recherche interdisciplinaire en informatique
de la santé - UdS




CHAIRE DE RECHERCHE EN MÉTHODOLOGIES
STATISTIQUES APPLIQUÉES AUX ENJEUX DE
SANTÉ ET PHÉNOMÈNES SOCIAUX




Objectifs de l'atelier

Objectifs de formation

- O1. Mieux cerner le rôle de la statistique inférentielle.
- O2. Approfondir des notions de méthodologie statistique.
- O3. Susciter la réflexion au niveau de biais d'analyse inhérents au contexte de collecte de données.
- O4. Apprendre à cerner la portée de l'utilisation d'éléments d'analyse ou d'IA.



Ce que j'aimerais qui soit retenu de la présentation




« tous les individus sont extrêmes si on considère suffisamment de leur caractéristiques »



Un mot sur la méthodologie de recherche

Règles générales



Ce qu'on doit retenir de l'atelier

- La façon dont les données sont/ont été collectées doit influencer la manière de les analyser + la portée des conclusions
- Primordial de chercher à nuancer, critiquer, confronter



La statistique inférentielle, qu'est-ce que c'est?

Inférence statistique?

Inférence statistique:

- Ensemble des techniques pour induire les caractéristiques (paramètres) inconnus d'une population à partir de celles observées auprès d'un échantillon
- Modélisation probabiliste de systèmes
- Estimation des paramètres, intervalles de confiance, tests

Idée phare derrière le processus d'inférence

Patron observé dans l'échantillon → reflet du patron observé dans la Population

Patron: éléments paramétrés d'équations probabilistes


Théorie des probabilités: quantification de la qualité du reflet en terme d'incertitude sur l'estimation des paramètres

Inférence vs prédiction

Inférence: À quel point les caractéristiques de l'échantillon sont-elles représentatives de celles de la population de laquelle il est issu?

Prédiction: À quel point est-il possible de prédire une issue sur la base d'une sélection de variables prédictives?

Procédure inférentielle illustrée



Questions typiques de nature inférentielles


- Dans la population A, le facteur d'exposition X est-il associé à l'issue Y ?
- La distribution dans la population A des caractères X est-elle différente de celle de ces caractères dans la population B?
- Dans la population A, y a-t-il une variation dans la variable Z à travers le temps?

Ingrédients essentiels

Modèle

Régression/Classification






Distribution (jointe)



$$Y = f_{\theta}(X) + \epsilon$$

$$\mathbb{P}(Y = 1 \mid X) = f_{\theta}(X)$$

$$X \sim f_{\theta}$$



Estimation

Étant donné un échantillon

$$(Y_1, X_1), \dots, (Y_n, X_n)$$

Modèle

Étant donné un échantillon

$$X_1, \dots, X_n$$

Régression/Classification

Distribution (jointe)

$$Y = f_{\theta}(X) + \epsilon$$

$$\mathbb{P}(Y = 1 \mid X) = f_{\theta}(X)$$

$$X \sim f_{\theta}$$

Maximisation de la vraisemblance

Moindres carrés

Fonctions de perte (locales)

Maximisation de la vraisemblance a posteriori

Maximisation de la vraisemblance conditionnelle

Maximisation de la vraisemblance locale

Résultat

$$\hat{f}_\theta$$


Statistique inférentielle



Qualité de $\hat{f}_\theta$ vis-à-vis du modèle de la population de laquelle l'échantillon est issu

Pour statuer sur la qualité d'estimation


- Hypothèses sur le modèle
 - Forme fonctionnelle (p.ex: linéaire, nonlinéaire, dimensionalité creuse etc)
 - Régularité
- Hypothèses sur l'échantillonnage
 - Lien entre les observations, p.ex: i.i.d., corrélation sérielle
 - Lien entre les données manquantes (au hasard, complètement au hasard, systématique...)



Traduction en terme d'hypothèses
structurelles probabilistes



Biais?
Variance?
Convergence?
Intervalle de confiance?



Cadre classique de la statistique inférentielle


Étant donné:

1. Devis échantillonnal
2. Modèle
3. Technique d'estimation




Ensemble minimal
d'hypothèses pour
garantir la validité de

$$\hat{f}_\theta$$




Estimation de biais +
variance



**Valide seulement vis-à-vis de
la population de laquelle est
issu l'échantillon**


À propos du devis échantillonnal...

Cerner la population: un enjeu en recherche



Population?

Ensemble des individus ayant une probabilité non nulle de se retrouver dans l'échantillon ou la base de données



Exemples

« Après analyse, le taux de mortalité se situe à 40%, avec un intervalle de confiance de [35,45] à un niveau $\alpha = 0,05$. »

- Peut-être normal si l'échantillon provient des soins intensifs...

« Le taux de mortalité lié à l'administration du vaccin contre la COVID est de 5%. »

- Peut-être normal si l'échantillon est constitué de dossiers rapportés à un organe de pharmacovigilance.

« L'âge moyen estimé des personnes utilisant la piste cyclable du Lac des Nations est de 65 ans. »

- Peut-être conséquent avec un échantillonnage ayant eu lieu les lundis de septembre entre 9h30 et 11h.



À propos du choix du modèle

Conséquence d'une erreur de spécification...

- Rejeter une hypothèse nulle à tort
- Ne pas rejeter une hypothèse nulle à tort
- ...

Compromis dans la flexibilité permise au niveau de la gamme d'effets explorés

Exemple

« Rejeter l'hypothèse d'une variation dans le taux d'hormone de régulation de l'appétit à travers les trimestres de grossesse en se basant sur un modèle linéaire mixte incorporant le temps en facteur linéaire, alors qu'on se serait attendu a priori à observer une augmentation du 1^{er} au 2^e trimestre, puis une diminution du 2^e au 3^e trimestre. »


$Y \sim \text{temps} + \text{effet aléatoire}$

vs

$Y \sim \text{temps} + (\text{temps} == 1) + \text{effet aléatoire}$

p-valeur > 0.5

p-valeur < 0.005



Ce que plusieurs modèles supposent

$X_1, \dots, X_n$ I.I.D. • Indépendantes
• De même distribution, égale à celle n'importe quel individu dans la population

ou

$Y_1 | X_1, \dots, Y_n | X_n$ Indépendantes + mêmes constantes distributionnelles

Degré d'adhérence à ces hypothèses → Nuance les résultats observés



Principales conclusions à tirer jusqu'ici

Cadre méthodologique de l'inférence statistique

Au-delà de l'utilisation d'un logiciel statistique et du calcul de p-valeurs

- Évaluation du devis échantillonnal et de la population concernée
- Analyse de la capacité du modèle à discerner les tendances pressenties
- Évaluation de l'adhérence aux critères de validité des estimés
- Documentation de la robustesse de l'approche

Qu'en est-il de la prédiction?

Apprentissage automatique/Apprentissage statistique

1. Devis échantillonnal
(données d'entraînement)
2. Modèle
3. Technique d'estimation



Ensemble minimal
d'hypothèses pour
garantir la validité de

$$\hat{f}_{\theta}$$

Exemple: interpolation/extrapolation

« Pourrait-on se fier à un algorithme entraîné sur la base de données longitudinales d'enfants entre 0 et 12 ans pour prédire la mortalité en CHSLD? »

Représentation du profil d'individus pour lesquels une prédiction est requise

Autres enjeux liés à l'échantillonnage

- Facteurs de confusion

$$X \xrightarrow{Z} Y$$

- Événements rares
- Données manquantes
- Validité temporelle/transportabilité

Identification de facteurs causaux


Associations



Causalité




Associations
observationnelles



Autre échantillon


Prédicteurs



Issue de santé

Traitement des symptômes sévères de la COVID

- Cohorte ISARIC (International Severe Acute Respiratory and emerging Infection Consortium)
- >800 000 individus
- Administration de stéroïdes → **Mortalité**



En résumé

Inférences et prédictions non valides si:

- Modèle erroné
- Échantillon non représentatif

Exemples d'études ou de déploiements d'algorithmes qui ont présentés des enjeux de représentativité échantillonnale?


Exercice 1

- Quels sont les critères qui vous permettent d'évaluer si les conclusions d'une étude s'appliquent à vous ou non?
- Quels sont les critères qui vous permettent d'évaluer si les prédictions d'un algorithme pourraient être applicables à vous ou non?



Inférence vs prédiction

Collecte de données



Modèle



Analyses/prédictions

Différents objectifs poursuivis

Inférence: À quel point les caractéristiques de l'échantillon sont-elles représentatives de celles de la population de laquelle il est issu?

Prédiction: À quel point est-il possible de prédire une issue sur la base d'une sélection de variables prédictrices?

Des cadres méthodologiques différents

Inférence:

- Prépécification des tests/analyses
- Proscrit d'itérer jusqu'à l'obtention d'effets significatifs...

Prédiction:

- Optimisation d'un critère en lien avec l'application projetée
Pouvoir prédictif global, compromis sensibilité/spécificité,...
- Choix du meilleur modèle possible à partir des données d'entraînement


39

Scandal des p-valeurs...

- Tests :
 - Calibrés pour conclure à tort à un effet significatif suivant la réalisation d'une expérience dans au plus α % des cas de même type
 - Probabilité de trouver trouver un effet faussement significatif suivant la réalisation de K expériences indépendantes: $1 - (1 - \alpha)^K$
 - Si $K = 5$ et $\alpha = 0.05$: 23%
 - Si $K = 10$ et $\alpha = 0.05$: 41%
 - Si $K = 100$ et $\alpha = 0.05$: 99.4%

Un problème du même type en prédiction

Calibration itérative d'un modèle suite à l'évaluation suivant le même ensemble de données tests



Bonnes pratiques

- Planification des expériences et des stratégies anticipées
- Documenter et rapporter ce qui a été réalisé
- Nuancer en conséquence

La place de la recherche exploratoire

Analyses à visées exploratoires vs confirmatoires

Un question de définition d'objectifs vis-à-vis de l'état de la littérature...

Exercice 2

Vous dirigez un centre de soins d'urgence. On vous propose l'implantation d'un outil prédicteur de la mortalité basé sur les informations patients disponibles à l'admission pour guider la mobilisation de ressources.

Sur quels critères baseriez-vous la décision de procéder à cette implantation?

Comment évalueriez-vous la qualité de cet outil?

Comment jugeriez-vous la pertinence de l'outil pour votre milieu de soin?

Conclusion

Des bonnes pratiques à mettre en place

- Chercher à documenter les limites des conclusions
- Plusieurs biais difficiles à mitiger