

Inférence statistique avec R: un cas d'étude

Jean-Philippe Morissette

Candidat au doctorat en mathématique

Groupe de recherche interdisciplinaire en
informatique de la santé – UdS

Chargé de cours

Département de mathématique, UdS



Table des matières

- Introduction
- Initiation à R
- Exploration d'un jeu de données: *Données sur le diabète gestationnel*
- Conclusion




Introduction

Qu'est-ce que R?

Characteristic	N = 102 [†]
Traitement	
Controle	51 / 102 (50%)
Intervention	51 / 102 (50%)
Gluc_T1	
N Non-missing/No. obs. (% Non-missing)	102.0/102.0 (100.0)
Mean (SD)	7.6 (0.8)
Median (Q1, Q3)	7.7 (7.1, 8.2)
Min, Max	5.9, 9.4
Gluc_T2	
N Non-missing/No. obs. (% Non-missing)	102.0/102.0 (100.0)
Mean (SD)	8.0 (0.8)
Median (Q1, Q3)	8.0 (7.5, 8.5)
Min, Max	6.2, 10.1



Characteristic	Beta	95% CI	p-value
Age	0.01	-0.01, 0.03	0.2
IMC	-0.01	-0.03, 0.01	0.4
Predia			
Non	—	—	
Oui	-0.04	-0.22, 0.14	0.6
Groupe_a_risque	0.32	0.06, 0.58	0.017
Abbreviation: CI = Confidence Interval			



```
1 classe ← classe ▷  
2 filter(BonsEtudiants==TRUE)
```

Pourquoi choisir R? (et pas python?)




 **posit**TM Connect



Initiation à R

Utilisation de RStudio



À nous de joueR! (0)

Pré-requis:

- *On suppose que vous avez R et RStudio d'installer sur votre machine.*
- *Vous avez téléchargé le répertoire de l'atelier sur votre machine.*

Si ce n'est pas déjà fait, ouvrez le fichier *AtelierR.R*. Si on vous demande avec quel logiciel vous souhaitez ouvrir le fichier, choisissez RStudio.

Nous allons explorer le tout ensemble pour commencer!

Quelques particularités à propos de R

- Assignment avec la flèche « <- »
- L'opérateur « c » pour la création de vecteurs
- Les commandes d'aide « ? » et « ?? »
- L'utilisation de librairies
- La lecture de fichiers au format csv
- La structure *dataframe* et *tibble*

À nous de jouer! (1)

Que font les commandes suivantes?

- `head(df_glucose)`
- `tail(df_glucose)`
- `glimpse(df_glucose)`
- `view(df_glucose)`
- `df_glucose[1,]`
- `df_glucose[c(1,3,5),]`
- `df_glucose[,1]`
- `df_glucose[2,2]`
- `df_glucose[df_glucose$Predia==1,]`
- `df_glucose$Age`

RetouR

Que font les commandes suivantes:

- `head(df_glucose)`
- `tail(df_glucose)`
- `glimpse(df_glucose)`
- `view(df_glucose)`
- `df_glucose[1,]`
- `df_glucose[c(1,3,5),]`
- `df_glucose[,1]`
- `df_glucose[2,2]`
- `df_glucose[df_glucose$Predia==1,]`
- `df_glucose$Age`

Affiche les premières lignes du jeu

Affiche les dernières lignes du jeu

Transposition de « head »

Ouvre le jeu de données dans R

Accède la ligne 1 du jeu

Accède les lignes 1, 3 et 5 du jeu

Accède la colonne 1 du jeu

Accède la ligne 2 et la colonne 2 du jeu

Accède les lignes où « Predia==1 »

Accède la colonne nommée « Age »

Le standard des données bien rangées

<i>df</i>	Variable l	...	Variable j	...	Variable p
Individu l					
...					
Individu i			df [i, j]		
...					
Individu n					

df [i,]

df [, j]



Manipulation de données

La majorité des manipulations de données que l'on doit faire rentrent dans l'une des catégories suivantes:

- Sélectionner des observations (donc des *lignes*!)
- Sélectionner des variables (donc des *colonnes*!)
- Ordonner les lignes
- Créer de nouvelles variables
- Créer des résultats sommaires (moyenne, proportion, nombre de cas, etc.)
- Créer des groupes

<u>df</u>	Variable 1	...	Variable j	...	Variable p
Individu 1					
...					
Individu i			<u>df [i, j]</u>		<u>df [i,]</u>
...					
Individu n			<u>df [, j]</u>		

Manipulation de données

Action

Sélectionner des observations

Sélectionner des variables

Ordonner les lignes

Créer de nouvelles variables

Créer des résultats sommaires

Créer des groupes

Verbe

filter(df, critère)

select(df, critère)

arrange(df, critère)

mutate(df, critère)

summarise(df, critère)

group_by(df, critère)



Manipulation de données (Exemples)

Exemples:

- Ordonnez le jeu de données en fonction de l'IMC des patientes.
- Créez une nouvelle variable qui correspond à la cote z des patientes pour ce qui est de leur IMC.
- **Pour chaque catégorie de la variable traitement, calculez la moyenne de l'IMC des patientes.**

Manipulation de données

Action

Sélectionner des observations
Sélectionner des variables
Ordonner les lignes
Créer de nouvelles variables
Créer des résultats sommaires
Créer des groupes

Verbe

filter(df, critère)
select(df, critère)
arrange(df, critère)
mutate(df, critère)
summarise(df, critère)
group_by(df, critère)



L'opérateur *pipe*

Le langage R dispose d'un opérateur particulier, appelé *pipe* « %>% ». Cet opérateur permet d'utiliser un objet comme premier argument d'une fonction, et peut être utilisé à répétition.

Par exemple,

```
df_glucose ← arrange(df_glucose, IMC)
```

est équivalent à

```
df_glucose ← df_glucose %>%  
  arrange(IMC).
```



L'opérateur *pipe* (Exemple)

Pour chaque catégorie de la variable traitement, calculez la moyenne de l'IMC des patientes.

Manipulation de données

Action

Sélectionner des observations
Sélectionner des variables
Ordonner les lignes
Créer de nouvelles variables
Créer des résultats sommaires
Créer des groupes

Verbe

filter(df, critère)
select(df, critère)
arrange(df, critère)
mutate(df, critère)
summarise(df, critère)
group_by(df, critère)



L'opérateur *pipe* (Exemple)

Pour chaque catégorie de la variable traitement (*créer des groupes*), calculez la moyenne de l'IMC des patientes (*créer des résultats sommaires*).

Manipulation de données

Action

Sélectionner des observations
Sélectionner des variables
Ordonner les lignes
Créer de nouvelles variables
Créer des résultats sommaires
Créer des groupes

Verbe

filter(df, critère)
select(df, critère)
arrange(df, critère)
mutate(df, critère)
summarise(df, critère)
group_by(df, critère)



L'opérateur *pipe* (Exemple)

Pour chaque catégorie de la variable traitement (*créer des groupes*), calculez la *moyenne* de l'IMC des patientes (*créer des résultats sommaires*).

```
df_glucose %>%  
  group_by(Traitement) %>%  
  summarise(mean(IMC))
```

Manipulation de données

Action

- Sélectionner des observations
- Sélectionner des variables
- Ordonner les lignes
- Créer de nouvelles variables
- Créer des résultats sommaires
- Créer des groupes

Verbe

- filter(df, critère)*
- select(df, critère)*
- arrange(df, critère)*
- mutate(df, critère)*
- summarise(df, critère)*
- group_by(df, critère)*



L'opérateur *pipe* (Exemple)

Pour chaque catégorie de la variable traitement (*créer des groupes*), calculez la *moyenne* de l'IMC des patientes (*créer des résultats sommaires*).

```
df_glucose %>%  
  group_by(Traitement) %>%  
  summarise(mean(IMC))
```

À partir du jeu de données `df_glucose`,
regrouper les observations en fonction du
traitement, **PUIS** calculer la *moyenne* de l'IMC.

Manipulation de données

Action

Sélectionner des observations
Sélectionner des variables
Ordonner les lignes
Créer de nouvelles variables
Créer des résultats sommaires
Créer des groupes

Verbe

filter(df, critère)
select(df, critère)
arrange(df, critère)
mutate(df, critère)
summarise(df, critère)
group_by(df, critère)



Manipulation de données

Exemple:

Supposons que l'on souhaite calculer l'IMC moyen des patientes ayant entre 25 et 30 ans, et ce en comparant les patientes qui ont reçu le traitement à celles qui ne l'ont pas reçu.

Manipulation de données

Action

Sélectionner des observations
Sélectionner des variables
Ordonner les lignes
Créer de nouvelles variables
Créer des résultats sommaires
Créer des groupes

Verbe

filter(df, critère)
select(df, critère)
arrange(df, critère)
mutate(df, critère)
summarise(df, critère)
group_by(df, critère)



Manipulation de données

Exemple:

Supposons que l'on souhaite **calculer l'IMC moyen** (*créer un résultat sommaire*) des patientes **ayant entre 25 et 30 ans** (*sélectionner des observations*), et ce en **comparant les patientes qui ont reçu le traitement à celles qui ne l'ont pas reçu** (*créer des groupes*).

Manipulation de données

Action

Sélectionner des observations
Sélectionner des variables
Ordonner les lignes
Créer de nouvelles variables
Créer des résultats sommaires
Créer des groupes

Verbe

filter(df, critère)
select(df, critère)
arrange(df, critère)
mutate(df, critère)
summarise(df, critère)
group_by(df, critère)



À vous de jouer! (2)

Action

Sélectionner des observations

Sélectionner des variables

Ordonner les lignes

Créer de nouvelles variables

Créer des résultats sommaires

Créer des groupes

Verbe

filter(df, critère)

select(df, critère)

arrange(df, critère)

mutate(df, critère)

summarise(df, critère)

group_by(df, critère)

Retour


Création d'une variable catégorique:

```
df_glucose ← df_glucose %>%  
  mutate(AgeCat = case_when(Age < 25 ~ 0,  
                             Age < 32 ~ 1,  
                             Age ≥ 32 ~ 2))
```








Calcul d'un compte:

```
df_glucose %>%  
  filter(Age > 30) %>%  
  count(Traitement)
```


Visualisation de données










Visualisation de données



Visualisation de données

L'ensemble des graphiques que l'on crée partagent certains éléments essentiels:

- On a besoin d'un jeu de données;
- On doit choisir quelle(s) variable(s) on aimerait afficher;
- On doit choisir une méthode de représentation des données.



Visualisation de données

Éléments essentiels

Choix du jeu de données

Choix de la ou des variable(s)


Choix de représentation

Fonction

`ggplot(df)`

`aes(x, y)`

`geom_...()`



Visualisation de données

Éléments essentiels

Choix du jeu de données

Choix de la ou des variable(s)

Choix de représentation


Fonction

`ggplot(df)`

`aes(x, y)`

`geom_...()`

Le principe général de la *grammaire des graphiques*, c'est d'**ajouter** les éléments essentiels et optionnels d'un graphique *une couche à la fois*. Ceci rend les graphiques manipulables et malléables.



Visualisation de données (Exemple)

Exemples:

- Construire un histogramme de l'âge des patientes.
- Construire un histogramme de l'âge des patientes ayant reçu le traitement et un autre pour celles ne l'ayant pas reçu.
- Construire un seul histogramme qui combine l'âge des patientes ayant reçu le traitement et celles ne l'ayant pas reçu.

Visualisation de données

Éléments essentiels

Choix du jeu de données

Choix de la ou des variable(s)

Choix de représentation

Fonction

`ggplot(df)`

`aes(x, y)`

`geom_...()`

Le principe général de la *grammaire des graphiques*, c'est d'**ajouter** les éléments essentiels et optionnels d'un graphique *une couche à la fois*. Ceci rend les graphiques manipulables et malléables.




Visualisation de données... en trichant!

Data visualization with ggplot2 : : CHEATSHEET




Basics

ggplot2 is based on the **grammar of graphics**, the idea that you can build every graph from the same components: a **data set**, a **coordinate system**, and **geoms**—visual marks that represent data points.



To display values, map variables in the data to visual properties of the geom (aesthetics) like **size**, **color**, and **x** and **y** locations.



Complete the template below to build a graph.

```
ggplot(data = <DATA>) +  
  <GEOM_FUNCTION> (mapping = aes(<MAPPINGS>)) +  
  stat(<STAT>, position = <POSITION>) +  
  <COORDINATE_FUNCTION> +  
  <FACET_FUNCTION> +  
  <SCALE_FUNCTION> +  
  <THEME_FUNCTION>
```

ggplot(data = mpg, aes(x = cty, y = hwy)) Begins a plot that you finish by adding layers to. Add one geom function per layer.

last_plot() Returns the last plot.

ggsave("plot.png", width = 5, height = 5) Saves last plot as 5" x 5" file named "plot.png" in working directory. Matches file type to file extension.

Aes

Common aesthetic values.

color and fill - string ("red", "#RRGGBB")

linetype - integer or string (0 = "blank", 1 = "solid", 2 = "dashed", 3 = "dotted", 4 = "dottedash", 5 = "longdash", 6 = "twodash")

size - integer (in mm for size of points and text)

linewidth - integer (in mm for widths of lines)

shape - integer (shape name or a single character ("a"))



Geoms

Use a geom function to represent data points, use the geom's aesthetic properties to represent variables.

Each function returns a layer.

GRAPHICAL PRIMITIVES

a <- ggplot(economics, aes(date, unemployment))

b <- ggplot(seals, aes(x = long, y = lat))

a + geom_blank() and a + expand_limits()

Ensure limits include values across all plots.

b + geom_curve(aes(yend = lat + 1,

xend = long + 1, curvature = 1) - x, yend, y, yend,

alpha, angle, color, curvature, linetype, size

a + geom_path(linetype = "butt",

linetype = "round", linetype = 1)

x, y, alpha, color, group, linetype, size

a + geom_polygon(aes(alpha = 50)) - x, y, alpha,

color, fill, group, subgroup, linetype, size

b + geom_rect(aes(xmin = long, ymin = lat,

xmax = long + 1, ymax = lat + 1) - xmax, xmin,

ymax, ymin, alpha, color, fill, linetype, size

a + geom_ribbon(aes(ymin = unemployment - 900,

ymax = unemployment + 900)) - x, y, ymax, ymin,

alpha, color, fill, group, linetype, size

LINE SEGMENTS

common aesthetics: x, y, alpha, color, linetype, size

b + geom_abline(aes(intercept = 0, slope = 1)

stat) - x, y, alpha, color, linetype, size

b + geom_vline(aes(intercept = long)

stat) - x, y, alpha, color, linetype, size

b + geom_segment(aes(yend = lat + 1, xend = long + 1)

stat) - x, y, alpha, color, linetype, size

b + geom_spoke(aes(angle = 1:1155, radius = 1)

stat) - x, y, alpha, color, linetype, size

ONE VARIABLE continuous

c <- ggplot(mpg, aes(hwy)); c2 <- ggplot(mpg,

stat = "bin")

x, y, alpha, color, fill, linetype, size

c + geom_area(aes(stat = "bin")

stat) - x, y, alpha, color, fill, linetype, size

c + geom_density(kernel = "gaussian")

x, y, alpha, color, fill, group, linetype, size, weight

c + geom_dotplot()

x, y, alpha, color, fill

c + geom_freapoly()

x, y, alpha, color, group, linetype, size

c + geom_histogram(binwidth = 5)

x, y, alpha, color, fill, linetype, size, weight

c2 + geom_qq(aes(sample = hwy))

x, y, alpha, color, fill, linetype, size, weight

discrete

d <- ggplot(mpg, aes(r))

stat = "bin")

d + geom_bar()

x, y, alpha, color, fill, linetype, size, weight

TWO VARIABLES

both continuous

e <- ggplot(mpg, aes(cty, hwy))

e + geom_label(aes(label = cty, nudge_x = 1,

nudge_y = 1) - x, y, label, alpha, angle, color,

family, fontface, hjust, lineheight, size, vjust

e + geom_point()

x, y, alpha, color, fill, shape, size, stroke

e + geom_quantile()

x, y, alpha, color, group, linetype, size, weight

e + geom_rug(sides = "bl")

x, y, alpha, color, linetype, size

e + geom_smooth(method = lm)

x, y, alpha, color, fill, group, linetype, size, weight

e + geom_test(aes(label = cty, nudge_x = 1,

nudge_y = 1) - x, y, label, alpha, angle, color,

family, fontface, hjust, lineheight, size, vjust

one discrete, one continuous

f <- ggplot(mpg, aes(class, hwy))

f + geom_col()

x, y, alpha, color, fill, group, linetype, size

f + geom_boxplot()

x, y, lower, middle, upper, ymax, ymin, alpha,

color, fill, group, linetype, shape, size, weight

f + geom_dotplot(binaxis = "y", stackdir = "center")

x, y, alpha, color, fill, group

f + geom_violin(scale = "area")

x, y, alpha, color, fill, group, linetype, size, weight

both discrete

g <- ggplot(diamonds, aes(cut, color))

g + geom_count()

x, y, alpha, color, fill, shape, size, stroke

e + geom_jitter(height = 2, width = 2)

x, y, alpha, color, fill, shape, size

THREE VARIABLES

sealsSz <- with(seals, sqrt(delta_long^2 + delta_lat^2)); l <- ggplot(seals, aes(long, lat))

l + geom_contour(aes(z = z))

x, y, z, alpha, color, group, linetype, size, weight

l + geom_contour_filled(aes(fill = z))

x, y, alpha, color, fill, group, linetype, size, subgroup

l + geom_raster(aes(fill = z), hjust = 0.5,

vjust = 0.5, interpolate = FALSE)

x, y, alpha, fill

l + geom_tile(aes(fill = z))

x, y, alpha, color, fill, linetype, size, width

continuous bivariate distribution

h <- ggplot(diamonds, aes(carat, price))

h + geom_bin2d(binwidth = c(0.25, 500))

x, y, alpha, color, fill, linetype, size, weight

h + geom_density_2d()

x, y, alpha, color, group, linetype, size

h + geom_hex()

x, y, alpha, color, fill, size

continuous function

i <- ggplot(economics, aes(date, unemployment))

i + geom_area()

x, y, alpha, color, fill, linetype, size

i + geom_line()

x, y, alpha, color, group, linetype, size

i + geom_step(direction = "hv")

x, y, alpha, color, group, linetype, size

visualizing error

df <- data.frame(gp = c("A", "B"), fit = 4.5, se = 1.2)

j <- ggplot(df, aes(gp, fit, ymin = fit - se, ymax = fit + se))

j + geom_crossbar(fatten = 2) - x, y, ymax,

ymin, alpha, color, fill, group, linetype, size

j + geom_errorbar() - x, ymax, ymin,

alpha, color, group, linetype, size, width

Also geom_errorbarh()

j + geom_linerange()

x, ymin, ymax, alpha, color, group, linetype, size

j + geom_pointrange() - x, y, ymin, ymax,

alpha, color, fill, group, linetype, shape, size

maps

Draw the appropriate geometric object depending on the

simple features present in the data. aes() arguments:

map_id, alpha, color, fill, linetype, linewidth.

nc <- sf::read(system.file("shape/nc.shp", package = "sf"))

ggplot(nc) +

geom_sf(aes(fill = AREA))

À vous de joueR! (3)

Éléments essentiels

Choix du jeu de données

Choix de la ou des variable(s)

Choix de représentation

Fonction

`ggplot(df)`


`aes(x, y)`

`geom_...()`

Le principe général de la *grammaire des graphiques*, c'est d'**ajouter** les éléments essentiels et optionnels d'un graphique *une couche à la fois*. Ceci rend les graphiques manipulables et malléables.

RetouR

Étude de la relation entre les deux mesures du glucose en fonction de l'appartenance à un groupe à risque.





Exploration d'un jeu de données: *Données sur le diabète gestationnel*

Mise en situation

Le diabète gestationnel est associé à des conséquences négatives telles que l'obésité et l'intolérance au glucose chez l'enfant, ainsi qu'à des risques plus élevés de diabète de type 2 et de maladies cardiovasculaires pour la mère.

Dans la littérature, on remarque une association forte et continue entre les niveaux de glucose maternelle du 3^e trimestre et l'augmentation du poids à la naissance ainsi que d'autres complications de la grossesse.

En cas de diabète gestationnel, le traitement usuel est de référer à l'équipe multidisciplinaire pour les grossesses à risque dans les hôpitaux.

Question de recherche

Une intervention en début de grossesse visant à améliorer la qualité de l'alimentation permet-elle d'améliorer le profil glycémique des personnes à risque de développer un diabète gestationnel?

Exploration du jeu de données

Avant de tenter de répondre directement à la question de recherche, une bonne pratique est d'explorer minimalement les données.

Dans ce cas-ci, on voudra:

- Jeter un coup d'œil aux statistiques descriptives du jeu;
- Comparer les groupes d'intérêt, s'il y a lieu.

À vous de jouer! (4)

On vous demande de comparer les statistiques descriptives du groupe « intervention » et du groupe « contrôle » pour les variables suivantes:

- Age
- Groupe_a_risque
- IMC
- Predia.

Pour une variable catégorique, on compare normalement uniquement les proportions. Pour une variable numérique, on compare normalement la moyenne, l'écart-type, la médiane (potentiellement avec les quartiles), le minimum et le maximum.


RetouR

Characteristic	Controle N = 51 [†]	Intervention N = 51 [†]	p-value ²
Age			<0.001
N Non-missing/No. obs. (% Non-missing%)	51.0/51.0 (100.0%)	51.0/51.0 (100.0%)	
Mean (SD)	27.2 (4.5)	30.6 (4.8)	
Median (Q1, Q3)	27.0 (24.0, 30.0)	30.0 (27.0, 35.0)	
Min, Max	17.0, 35.0	22.0, 39.0	
Groupe_a_risque	6 / 51 (12%)	4 / 51 (7.8%)	0.7
IMC			<0.001
N Non-missing/No. obs. (% Non-missing%)	51.0/51.0 (100.0%)	51.0/51.0 (100.0%)	
Mean (SD)	23.8 (2.0)	30.3 (2.0)	
Median (Q1, Q3)	23.8 (22.2, 25.1)	30.2 (29.0, 31.4)	
Min, Max	19.8, 29.7	26.1, 35.8	
PrediaCat			>0.9
Non	38 / 51 (75%)	39 / 51 (76%)	
Oui	13 / 51 (25%)	12 / 51 (24%)	

[†] n / N (%)

Survol du modèle de régression linéaire


Étude de la relation entre les deux mesures du glucose en fonction de l'appartenance à un groupe à risque.



Survol du modèle de régression linéaire

- La variable d'intérêt, Y_i , est continue.
- Modélisation de la moyenne à l'aide d'une fonction linéaire: $\mathbb{E}[Y_i|x_i] = \beta_0 + \beta_1 x_i$.
- Interprétation des paramètres: ordonnée à l'origine (β_0) et pente (β_1).
- **Hypothèses.**
- Inférence.

Étude de la relation entre les deux mesures du glucose en fonction de l'appartenance à un groupe à risque.



Survol du modèle de régression linéaire (Prédicteurs cat.)

Lorsque l'on inclut des variables catégoriques (au format *factor*) dans un modèle linéaire à l'aide de R, la première catégorie devient ce qu'on appelle le groupe de référence. Les autres catégories seront quant à elles comparées au groupe de référence. On cherche alors à comprendre comment les autres catégories se distinguent, si c'est le cas, du groupe de référence.

Survol du modèle de régression linéaire (Prédicteurs cat.)

Lorsque l'on inclut des variables catégoriques (au format *factor*) dans un modèle linéaire à l'aide de R, la première catégorie devient ce qu'on appelle le groupe de référence. Les autres catégories seront quant à elles comparées au groupe de référence. On cherche alors à comprendre comment les autres catégories se distinguent, si c'est le cas, du groupe de référence.

La patiente fait partie de la catégorie d'âge...

- Moins de 25 ans
- Au moins 25 ans et moins de 32 ans
- Au moins 32 ans

Survol du modèle de régression linéaire (Prédicteurs cat.)

Lorsque l'on inclut des variables catégoriques (au format *factor*) dans un modèle linéaire à l'aide de R, la première catégorie devient ce qu'on appelle le groupe de référence. Les autres catégories seront quant à elles comparées au groupe de référence. On cherche alors à comprendre comment les autres catégories se distinguent, si c'est le cas, du groupe de référence.

La patiente fait partie de la catégorie d'âge...

- Moins de 25 ans → Groupe de référence
- Au moins 25 ans et moins de 32 ans → Groupe d'intérêt #1
- Au moins 32 ans → Groupe d'intérêt #2

Survol du modèle de régression linéaire (Inférence)

Pour les patientes de moins de 25 ans:

$$\hat{y}_{T_2} = 1 + 0,91x_{T_1}$$

Characteristic	Beta	95% CI	p-value
(Intercept)	1.0	0.23, 1.9	0.013
Gluc_T1	0.91	0.81, 1.0	<0.001
AgeCat			
<25	—	—	
>=25, < 32	-0.02	-0.23, 0.19	0.9
>=32	0.11	-0.12, 0.35	0.3

Abbreviation: CI = Confidence Interval

Notion de valeur- p

Étant donné un certain test d'hypothèses où l'on confronte l'hypothèse nulle H_0 avec l'hypothèse alternative H_1 , la valeur- p représente **la probabilité d'obtenir des résultats au moins aussi « extrêmes » que ceux que l'on a observé.**

Par exemple, on pourrait considérer le test d'hypothèses suivant:

$$\begin{cases} H_0: \mu_{\text{Contrôle}} = \mu_{\text{Intervention}} \\ H_1: \mu_{\text{Contrôle}} \neq \mu_{\text{Intervention}} \end{cases}.$$

Notion de valeur- p (Exemple)

Characteristic	Controle N = 51 ¹	Intervention N = 51 ¹	p-value ²
Age			<0.001
N Non-missing/No. obs. (% Non-missing%)	51.0/51.0 (100.0%)	51.0/51.0 (100.0%)	
Mean (SD)	27.2 (4.5)	30.6 (4.8)	
Median (Q1, Q3)	27.0 (24.0, 30.0)	30.0 (27.0, 35.0)	
Min, Max	17.0, 35.0	22.0, 39.0	

Survol du modèle de régression linéaire (Inférence)

Pour les patientes de moins de 25 ans:

$$\hat{y}_{T_2} = 1 + 0,91x_{T_1}$$

Pour les patientes d'au moins 25 ans,
moins de 32 ans :

$$\hat{y}_{T_2} = 0,98 + 0,91x_{T_1}$$

Pour les patientes d'au moins 32 ans:

$$\hat{y}_{T_2} = 1,11 + 0,91x_{T_1}$$

Characteristic	Beta	95% CI	p-value
(Intercept)	1.0	0.23, 1.9	0.013
Gluc_T1	0.91	0.81, 1.0	<0.001
AgeCat			
<25	—	—	
>=25, < 32	-0.02	-0.23, 0.19	0.9
>=32	0.11	-0.12, 0.35	0.3

Abbreviation: CI = Confidence Interval

Utilisation de R pour la régression linéaire

La commande « `lm` » permet de construire un *linear model*. Il s'agit d'une commande disponible parmi les librairies de bases de R.


```
reg.lin ← lm( formula, data )
```

- **Formula:** Correspond au modèle qui nous intéresse.
On l'écrit: $y \sim x_1 + x_2 + \dots + x_p$
- **Data:** Correspond au jeu de données que l'on souhaite utiliser.

Question de recherche, précisée!

Une intervention en début de grossesse visant à améliorer la qualité de l'alimentation permet-elle d'améliorer le profil glycémique des personnes à risque de développer un diabète gestationnel?


Introduction au modèle de régression logistique



Introduction au modèle de régression logistique

Particularités du modèle de régression logistique:

- La variable d'intérêt, Y_i , prend les valeurs 0 ou 1.
- Modélisation de la probabilité des deux réponses possibles:
 - $\mathbb{P}(Y_i = 1|X_i = x_i) = \frac{\exp(\beta_0 + \beta_1 x_i)}{1 + \exp(\beta_0 + \beta_1 x_i)}$
 - $\mathbb{P}(Y_i = 0|X_i = x_i) = \frac{1}{1 + \exp(\beta_0 + \beta_1 x_i)}$
- Interprétation des paramètres en termes de cotes (*odds*) ou de rapport de cotes (*odds ratio*).



Interprétation des paramètres (Exemple: prédicteur discret)

Modélisation

- Y : Avoir un cancer du poumon (oui = 1, non = 0)
- X : Fumer (oui = 1, non = 0)

Supposons que la probabilité de cancer du poumon si $X = 0$ est 5/100.

- La cote (*odds*) associée est $\frac{5/100}{95/100} = \frac{5}{95} = \frac{1}{19}$. Ainsi, si on ne fume pas, il est 19 fois plus probable de ne pas avoir un cancer du poumon que d'en avoir un.

Supposons que la probabilité de cancer du poumon si $X = 1$ est 20/100.

- La cote (*odds*) associée est $\frac{20/100}{80/100} = \frac{20}{80} = \frac{1}{4}$. Ainsi, si on fume, il est 4 fois plus probable de ne pas avoir de cancer du poumon que d'en avoir un.
- Le rapport des cotes (*odds ratio*) correspond à $\frac{1/4}{1/19} = \frac{19}{4}$. Il est plus probable d'avoir le cancer si on fume que si on ne fume pas.

COTE

$$\text{Cote}(A) = \frac{\mathbb{P}(A)}{1 - \mathbb{P}(A)}$$

CAS OÙ $x_i = 0$

$$\frac{\mathbb{P}(Y_i = 1 | X_i = 0)}{\mathbb{P}(Y_i = 0 | X_i = 0)} = e^{\beta_0}$$

CAS OÙ $x_i = 1$

$$\frac{\mathbb{P}(Y_i = 1 | X_i = 1)}{\mathbb{P}(Y_i = 0 | X_i = 1)} = e^{\beta_0 + \beta_1}$$

RAPPORT DES COTES

$$e^{\beta_1} = \frac{e^{\beta_0 + \beta_1}}{e^{\beta_0}}$$

Interprétation des paramètres (prédicteur continu)

Dans le cas d'un prédicteur continu, le rapport des cotes du prédicteur X indique comment la cote va varier en fonction d'une augmentation d'une unité du prédicteur. Encore une fois, on suppose que les autres prédicteurs demeurent constants.

À noter qu'il s'agit d'un effet *multiplicateur*.

COTE

$$\text{Cote}(A) = \frac{\mathbb{P}(A)}{1 - \mathbb{P}(A)}$$

CAS OÙ $x_i = x$

$$\frac{\mathbb{P}(Y_i = 1 | X_i = x)}{\mathbb{P}(Y_i = 0 | X_i = x)} = e^{\beta_0 + \beta_1 x}$$

CAS OÙ $x_i = x + 1$

$$\frac{\mathbb{P}(Y_i = 1 | X_i = x + 1)}{\mathbb{P}(Y_i = 0 | X_i = x + 1)} = e^{\beta_0 + \beta_1 (x + 1)}$$

RAPPORT DES COTES

$$e^{\beta_1} = \frac{e^{\beta_0 + \beta_1 (x + 1)}}{e^{\beta_0 + \beta_1 x}}$$

Utilisation de R pour la régression logistique

La commande « `glm` » permet de construire un *general linear model* (qui correspond à une grande classe de modèle incluant la régression logistique). Il s'agit d'une commande disponible parmi les librairies de bases de R.

```
reg.logis ← glm( formula, family, data, )
```

- **Formula:** Correspond au modèle qui nous intéresse.
On l'écrit: $y \sim x_1 + x_2 + \dots + x_p$
- **Family:** Permet de préciser quel GLM on souhaite utiliser.
On précise “`binomial`” pour la régression logistique.
- **Data:** Correspond au jeu de données que l'on souhaite utiliser.

Que peut-on dire par rapport à notre objectif?

Une intervention en début de grossesse visant à améliorer la qualité de l'alimentation permet-elle d'améliorer le profil glycémique des personnes à risque de développer un diabète gestationnel?

Plus précisément,

- on considère que l'intervention est efficace si le changement dans la mesure du test oral pris au 3^e et au 1^{er} trimestre est inférieur à 0.3mmol/L.
- Est-ce que la proportion de patientes ayant un changement dans la mesure du test oral pris au 3^e et au 1^{er} trimestre inférieur à 0.3mmol/L est plus élevée chez le groupe intervention que chez le groupe contrôle?

Characteristic	OR	95% CI	p-value
TraitementCat			
Controle	—	—	
Intervention	6.68	1.27, 39.5	0.029
Age	0.92	0.84, 1.01	0.089
IMC	0.84	0.67, 1.03	0.11
Groupe_a_risque	0.12	0.01, 0.76	0.061
Predia	0.80	0.29, 2.17	0.7
Abbreviations: CI = Confidence Interval, OR = Odds Ratio			



Conclusion

Introduction à R avec un cas d'étude

- Pourquoi utiliser R?
- Les librairies de références: Tidyverse et ggplot2
(qui appuient les grandes étapes de l'analyse de données)
- Les modèles de régressions: régression linéaire et régression logistique
- Cas d'étude

Références

- Ihaka, R., & Gentleman, R. (1996). R: a language for data analysis and graphics. *Journal of computational and graphical statistics*, 5(3), 299-314.
- Statistics Team. (s.d.). *Introduction to R for Health Data Science*. Repéré en ligne le 15 avril 2025, à partir de https://bookdown.org/m_p_sperrin/introduction_to_r/https://r4ds.had.co.nz/index.html
- Wickham, H., Çetinkaya-Rundel, M., & Grolemund, G. (2023). *R for Data science: Import, Tidy, Transform, Visualize, and Model Data*. O'Reilly Media
- Wickham, H. (2016). ggplot2. In Use R! <https://doi.org/10.1007/978-3-319-24277-4>
- Boehmke, B. C., PhD. (2016). *Data Wrangling with R*. Springer.
- Peng, R. D. (2012). *R Programming for data science*.